Manuel d'architecture — Onboarding catalogue MedCare

Oct 19, 2026 · @Rassoul

1. Contexte et besoin

MedCare doit construire un **programme d'onboarding catalogue** opéré par MedCare : on collecte le fichier de la structure tel qu'il est, on le normalise, on le rattache au référentiel, un humain tranche les doutes, et la structure trouve son catalogue prêt à sa première connexion. Ce n'est pas un bouton d'import côté structure : c'est une chaîne de production interne, qui doit tenir 10, puis 50, puis 500 structures sans que l'effort grandisse au même rythme.

Constat terrain (Abdoul). Les secrétaires n'ont pas le temps de saisir les actes un par un dans le tableau de bord structure. Le site actuel suppose qu'elles le feront : c'est le maillon qui casse l'onboarding.

Les deux exigences d'Abdoul.

- **Générique** : la mécanique ne connaît pas la biologie. Elle travaille sur « un pilier, des actes, des alias ». L'imagerie, les explorations fonctionnelles et les consultations suivent sans réécriture.
- **Proposer plutôt qu'échouer** : aucune ligne n'est rejetée en silence. Chaque ligne sort avec une issue (reconnu / à confirmer / inconnu) et, sauf exception, une proposition.

Ce que l'existant ne fait pas. L'import actuel (`healthcare/catalog_excel.py`) et l'outil autonome `catalog_importer.py` ont été testés sur le fichier imagerie *ACTES ET TARIFICATIONS* :

Point	Existant	Conséquence
Qui lance l'import	La structure connectée, depuis son compte	Impossible sans compte créé : bloque l'onboarding assisté
Fichier .ods	Plantage (traité comme .xlsx)	Fichier rejeté entièrement
Fichier sans colonne « Acte »	« En-têtes non reconnus »	Même converti en .xlsx : 0 ligne lue sur 112
Ligne non trouvée	Rejetée	Contraire à « proposer plutôt qu'échouer »

Point	Existant	Conséquence
Prix vide	Fixé à 0 FCFA	Risque de publier un examen gratuit par erreur
Lexique	Dictionnaire `MEDICAL_SYNONYMS` codé en dur	Aucune validation humaine n'enrichit le système
Référentiel	~92 actes à plat, sans bilans	Le référentiel biologie en compte 415, dont 17 bilans
Traçabilité	Aucune trace des décisions ni du fichier source	Impossible d'auditer ou d'annuler un import

Le prototype livré (162.19.67.106:8085) n'a pas pu être consulté depuis cet environnement. Ce manuel sert de référence pour le corriger : il définit le besoin sur ses vrais axes (identité de la structure, chaîne de traitement, boucle d'apprentissage), pas sur l'écran d'upload.

2. Principes directeurs

Sept règles cadrent toutes les décisions techniques qui suivent ; un choix qui en viole une doit être justifié par écrit.

1. **La structure existe avant son catalogue.** Aucun traitement de fichier sans identifiant MedCare de structure. Le compte utilisateur, lui, peut venir après (section 3).
2. **On ne perd jamais la donnée brute.** Le fichier original, chaque cellule lue et chaque décision sont conservés. La normalisation produit une copie, jamais un écrasement.
3. **Staging d'abord, production ensuite.** Le fichier vit dans une zone de travail isolée. Seule une étape de publication explicite écrit dans les tables du catalogue en production.
4. **Le moteur ne connaît que des piliers, des actes et des alias.** Toute connaissance métier (abréviations, mots discriminants, seuils) est de la donnée paramétrable par pilier, pas du code.
5. **Une ligne = une issue + une proposition.** Le rapprochement classe et propose ; il ne rejette pas. Seul un humain dit « hors référentiel ».
6. **L'automatique ne valide que ce qui est sûr.** En santé, une erreur silencieuse coûte plus cher qu'un clic de confirmation. La largeur de l'automatique s'élargit par calibration mesurée, pas par intuition.
7. **Chaque validation enrichit le lexique.** Le coût marginal d'un onboarding doit baisser à chaque structure traitée : c'est la métrique qui juge l'architecture.

3. Prérequis : identité de la structure et cycle de vie

Le prérequis bloquant est l'identifiant : on ne peut rien publier tant que la structure n'existe pas dans `OrganismeDeSante`. Or aujourd'hui une structure n'existe que si elle a créé son compte, car `OrganismeDeSante.user` est un `OneToOne(User)` obligatoire. La réponse retenue est la **pré-inscription par MedCare**, avec un compte que la structure « réclame » ensuite.

3.1 Pré-inscription et réclamation du compte

- MedCare crée la fiche structure (nom, type, pilier(s), téléphone, e-mail, NINEA si connu) sans compte utilisateur actif. Elle reçoit son identifiant MedCare dès ce moment.
- **Dédoublonnage avant création** : recherche sur NINEA, téléphone, e-mail et nom approché. Si une structure correspond, on rattache le dossier à la fiche existante au lieu d'en créer une seconde.
- Le lien envoyé au client est un **lien d'onboarding signé** (jeton à usage unique, lié à l'identifiant de la structure, avec expiration). Il sert à déposer le fichier et, plus tard, à activer le compte.
- À l'activation, la structure choisit son mot de passe : le `User` est créé ou activé et rattaché à la fiche déjà remplie.
- Réponse à « sait-on si le client a créé son compte ? » : oui, à tout instant, par le champ `compte_active_le` (vide = pas encore réclamé) et le statut d'onboarding ci-dessous.

3.2 Statut d'onboarding

Un champ `onboarding_status` sur la structure porte le cycle de vie. Chaque transition est horodatée et attribuée (qui, quand).

Statut	Signification	Sortie
`pre_inscrite`	Fiche créée par MedCare, identifiant attribué	Fichier reçu
`fichier_recu`	Au moins un fichier déposé dans le dossier	Analyse terminée
`en_validation`	Lignes à confirmer ou inconnues en attente d'un opérateur	Toutes les lignes ont une décision
`pret_a_publier`	Catalogue complet en staging, prix contrôlés	Publication

Statut	Signification	Sortie
`publie_a_confirmer`	Catalogue écrit en production, non visible des patients	La structure confirme ses tarifs
`actif`	Compte réclamé, catalogue confirmé et visible	—

La publication ne dépend pas de l'activation du compte : MedCare peut tout préparer avant. La **visibilité patient**, elle, attend que la structure ait confirmé ses tarifs, car le prix engage la structure, pas MedCare.

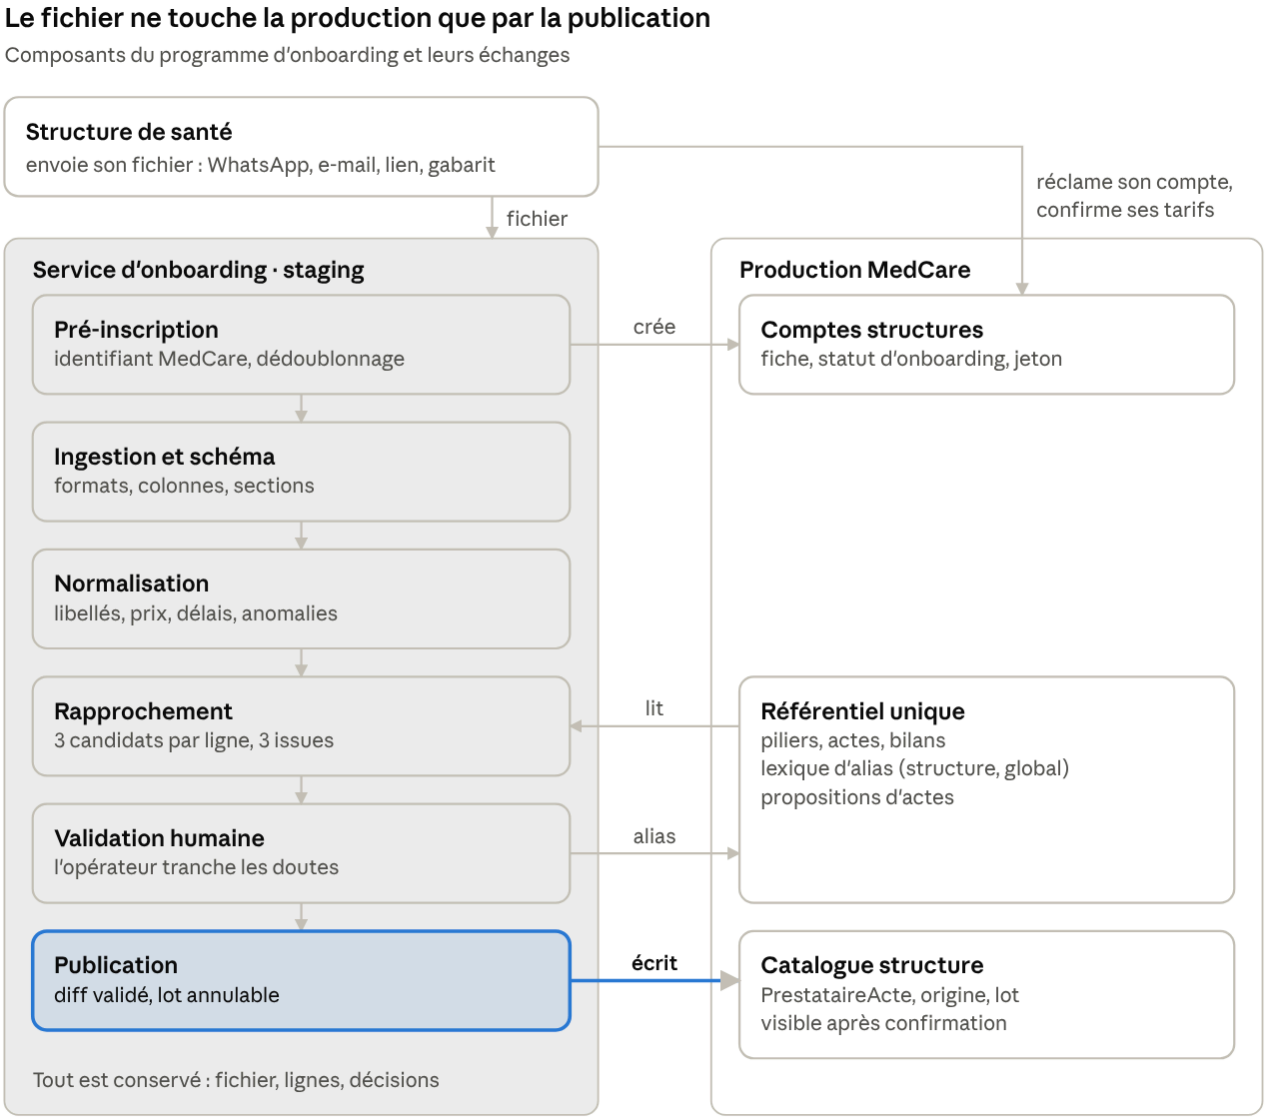
3.3 Environnement séparé

La proposition d'un environnement à part est retenue, avec une frontière précise :

- **Service d'onboarding séparé** (back-office interne, ex. `onboarding.medcare.sn`), avec son propre schéma de base `onboarding` : fichiers, lignes brutes, propositions, décisions. Les données sales n'entrent jamais dans les tables de production.
- **Le référentiel reste unique**, en production. Le service le lit (copie synchronisée et versionnée) et ne le modifie que par la voie gouvernée des alias et des propositions d'actes (section 9).
- **Une seule porte d'écriture vers la production** : l'API de publication (section 10). Elle est la seule à créer ou mettre à jour des `PrestataireActe`.
- Hébergement : même cloud souverain que la plateforme, car les fichiers sont des données de structures de santé (périmètre CDP).

4. Architecture cible

Le programme est une chaîne en six étapes dans un service séparé ; il ne lit la production que pour le référentiel et n'y écrit que par deux portes : les alias validés et la publication du catalogue.



architecture cible · 6 étapes en staging, 3 composants en production

La structure n'intervient qu'aux deux bouts : elle envoie un fichier, puis réclame son compte et confirme ses tarifs. Tout le travail entre les deux est fait par MedCare, en staging.

5. Modèle de données

Le modèle tient en trois blocs : le **référentiel** (production, partagé par tout MedCare), le **dossier d'onboarding** (staging, par structure) et l'**offre publiée** (production, `PrestataireActe`). Rien dans le modèle ne nomme la biologie : le pilier est une clé étrangère comme une autre.

5.1 Référentiel (production) — évolutions de l'existant

Table	Champs clés	Changement
`ServiceMedical` (pilier)	id, name, slug, `matching_config` (JSON)	Ajout : paramètres de rapprochement par pilier (seuils, abréviations, mots discriminants)
`ActeMedical`	id, code, name, pilier, `type_service`, `kind` (`acte` / `bilan`), is_active	Ajout de `kind` et `type_service` (ex. Hématologie, Échographie) ; `reference_price` reste indicatif
`ActeComposant` (nouveau)	bilan_id → ActeMedical, acte_id → ActeMedical, ordre	Un bilan pointe vers ses actes unitaires (ex. Bilan hépatique → ASAT, ALAT, GGT, PAL, bilirubines)
`ActeAlias` (nouveau)	id, acte_id, `alias_brut`, `alias_norm`, `scope` (`global` / `structure`), organisme_id (si scope structure), `statut` (`candidat` / `actif` / `ambigu` / `suspendu`), `origine` (`seed` / `validation`), cree_par, valide_par, nb_utilisations, created_at	Remplace le dictionnaire `MEDICAL_SYNONYMS`. Unicité : (`alias_norm`, pilier, `scope`, organisme_id)
`ActeProposition` (nouveau)	id, libelle_source, pilier, organisme_origine, propose_par, statut (`a_examiner` / `cree` / `fusionne` / `refuse`), acte_cree_id	File des libellés « hors référentiel » que le référent médical examine

5.2 Dossier d'onboarding (schéma `onboarding`, staging)

Table	Champs clés	Rôle
`Dossier`	id, organisme_id, statut, canal (`assiste` / `gabarit` / `self_service`), operateur_id, created_at	Un onboarding (ou une mise à jour annuelle) d'une structure

Table	Champs clés	Rôle
`FichierSource`	id, dossier_id, nom, sha256, format, feuille, chemin_stockage, depose_par, created_at	Le fichier original, immuable. Le hash évite de retraiter deux fois le même fichier
`ProfilSchema`	id, fichier_id, ligne_entete, roles_colonnes (JSON), mode_sections, confiance, valide_par, organisme_id	La lecture détectée du fichier. Conservé par structure pour réimporter la version suivante sans recalibrer
`LigneBrute`	id, fichier_id, num_ligne, section, cellules (JSON), libelle_brut, prix_brut, delai_brut	Copie fidèle de chaque ligne lue, avec le contexte de section
`LigneNormalisee`	ligne_id, libelle_norm, libelle_contextualise, prix (nullable), devise, delai_code, anomalies (liste)	Résultat de la normalisation, recalculable à tout moment depuis la ligne brute
`Proposition`	ligne_id, acte_id, rang (1 à 3), score, methode, explication	Les trois meilleurs candidats, avec la raison du score
`Decision`	ligne_id, issue (`reconnu` / `confirme` / `corrige` / `hors_referentiel` / `ignoree`), acte_id, prix_retenu, decide_par (`auto` ou utilisateur), decide_le, alias_cree_id	La décision finale ligne par ligne, auditable
`LotPublication`	id, dossier_id, version, nb_crees, nb_maj, nb_inchanges, nb_absents, publie_par, publie_le	Une publication vers la production, annulable

5.3 Offre publiée (production) — évolutions de `PrestataireActe`

- `price` devient nullable, avec `prix_statut` (`renseigne` / `sur_devis` / `manquant`) : fin du « vide = 0 FCFA ».
- `origine` (`onboarding` / `saisie_manuelle` / `reimport`) et `lot_publication_id` : on sait d'où vient chaque tarif et on peut annuler un lot.
- `libelle_structure` : le libellé tel que la structure l'écrit, affichable sur sa fiche et utile au support.
- `confirme_par_structure_le` : la date à laquelle la structure a validé ce tarif. Vide = non visible des patients.
- Contrainte inchangée : `UNIQUE(organisme, acte)`.

5.4 Sur `OrganismeDeSante`

- `user` devient nullable (ou un `User` inactif est créé à la pré-inscription : voir décision D1, section 14).
- Ajouts : `onboarding_status`, `compte_active_le`, `ninea`, `jeton_onboarding` (haché) + `jeton_expire_le`.

6. Ingestion et détection de schéma

L'ingestion transforme « n'importe quel fichier » en lignes brutes typées, en déduisant la structure du fichier au lieu de l'exiger. L'opérateur valide cette lecture en un écran avant tout rapprochement.

6.1 Formats acceptés

Format	Lecture	Phase
.xlsx, .xlsm	openpyxl, valeurs calculées, toutes les feuilles	V1
.ods	odfpy (ou conversion LibreOffice headless)	V1
.xls (ancien Excel)	Conversion LibreOffice headless → .xlsx	V1
.csv, .txt	Détection d'encodage (utf-8, cp1252, latin-1) et du séparateur	V1
PDF texte	Extraction des tableaux (pdfplumber)	V2
PDF scanné, photo d'une grille tarifaire	OCR puis extraction assistée, toujours en « à confirmer »	V2

La détection de format se fait sur la signature du fichier, pas sur l'extension (le fichier imagerie .ods plante l'outil actuel pour cette raison).

6.2 Détection du schéma en quatre passes

1. **Profil des colonnes.** Pour chaque colonne : part de cellules texte, numériques, au format prix (`20000 F`, `20 000 FCFA`, `20.000`), au format délai (`24h`, `48 h`, `sur RDV`), longueur moyenne du texte.
2. **Rôle des colonnes.** Les mots d'en-tête servent d'indice s'ils existent (acte, examen, désignation, libellé, prix, tarif…) ; à défaut, le profil décide : la colonne texte la plus longue = libellé, la colonne au format prix = prix. Les en-têtes ne sont plus obligatoires.

3. **Lignes de section.** Une ligne avec du texte et sans prix, ou dont la cellule prix vaut « PRIX », est un **titre de section** (ex. `ECHOGRAPHIES`, `SCANNER`, `IRM`). Elle n'est pas un acte : elle devient le contexte des lignes suivantes, jusqu'au titre suivant.
4. **Recollage des cellules.** Un libellé éclaté sur plusieurs colonnes (`SCANNER DU` | `MASSIF FACIAL`) est recollé. Les lignes vides et les lignes de totaux sont écartées avec un motif.

Le résultat est un `ProfilSchema` avec un score de confiance. Sous un seuil, ou à la première lecture d'une structure, l'opérateur voit un aperçu des 20 premières lignes avec le rôle attribué à chaque colonne, et corrige d'un clic.

6.3 Ce que la section apporte au rapprochement

Le contexte de section sert deux fois :

- **Compléter le libellé** : `ABDOMINALE` sous `ECHOGRAPHIES` devient `échographie abdominale` (le libellé contextualisé est rapproché, le brut est conservé).
- **Restreindre la recherche** : une section reconnue (échographie, scanner, hématologie…) limite les candidats au pilier et au type de service correspondants, ce qui élimine les faux rapprochements entre piliers.

Plusieurs feuilles = plusieurs flux, chacun avec son profil. Le nom de la feuille sert aussi d'indice de pilier.

7. Normalisation

La normalisation rend deux libellés comparables sans en changer le sens : elle unifie la forme (casse, accents, ponctuation, abréviations) mais ne corrige pas les fautes, qui relèvent du rapprochement flou. Elle est déterministe et recalculable : changer une règle relance la normalisation sur les lignes brutes, sans réimporter.

7.1 Libellés — pipeline

1. Unicode NFKD, suppression des accents, minuscules.
2. Sigles compactés : `N.F.S.` → `nfs`, `E.C.G` → `ecg`.
3. Ponctuation et symboles → espaces, en gardant `+` et `/` comme marqueurs de composition (utiles pour les bilans, section 8.4).
4. **Expansion des abréviations du pilier** (donnée, pas code) : `ac` → `anticorps`, `ag` → `antigene`, `echo` → `echographie`, `radio` / `rx` → `radiographie`, `tdm` → `scanner`, `cv` → `charge virale`…
5. Suppression des mots vides (de, du, la, le, et…) pour la comparaison par mots ; la chaîne complète est gardée pour la comparaison caractère par caractère.

6. Repérage des **mots discriminants** du pilier, conservés tels quels : en biologie `igg`, `igm`, `t3`, `t4`, `ft4`, `recherche`, `serologie`, `pcr`, `urinaire`, `plasmatique` ; en imagerie `face`, `profil`, `droit`, `gauche`, `bilateral`, `doppler`, `injection`.

7.2 Prix

Entrée	Sortie	Statut
`20000 F`, `20 000 FCFA`, `20.000`, `20000`	20000	`renseigne`
vide	null	`manquant` — bloque la publication de la ligne
`sur devis`, `variable`	null	`sur_devis`
`gratuit`, `offert`	0	`renseigne`, avec confirmation explicite
texte non lisible, négatif	null	anomalie, à corriger

Contrôle de vraisemblance : un prix hors de la fourchette observée pour le même acte chez les autres structures (ou à plus de 3 fois le prix médian du type de service) est signalé. Exemple : `TOGD 700000 F` dans un fichier où les examens spéciaux valent 60 000 à 100 000 F est très probablement un zéro de trop.

7.3 Délais

Table de correspondance existante (`DELAI_NORMALIZATION_MAP`) reprise telle quelle et déplacée en donnée. Un délai non reconnu reste vide avec un avertissement : il ne bloque pas la publication.

8. Algorithme de rapprochement

Le rapprochement calcule pour chaque ligne ses **trois meilleurs candidats** avec un score et une explication, puis classe la ligne selon des règles distinctes du calcul. Calculer et décider sont séparés : on peut élargir l'automatique en changeant une règle de classement, sans toucher au moteur.

8.1 Cascade de recherche

Les étapes s'enchaînent ; la première qui trouve un candidat exact s'arrête, les autres alimentent les propositions.

1. **Identifiant MedCare** (colonne ID ou code, cas du gabarit) → score 1,00.

2. **Nom normalisé exact** d'un acte du pilier → 1,00.
3. **Alias actif** : d'abord les alias propres à la structure, puis les alias globaux → 1,00 (sauf alias `ambigu`).
4. **Libellé contextualisé** (section + libellé, ex. `echographie abdominale`) → refait les étapes 2 et 3.
5. **Rapprochement flou** sur tous les noms et alias du pilier (et du type de service si la section est reconnue) → score continu.
6. **Décomposition** si le libellé contient `+`, `/`, `et` ou commence par `bilan` → rapprochement des morceaux, puis recherche du bilan correspondant (8.4).

Si le pilier est inconnu (pas de section, structure multi-piliers), la recherche porte sur tous les piliers actifs de la structure, avec une pénalité pour les piliers qu'elle n'a pas déclarés.

8.2 Score flou

Trois mesures complémentaires, pondérées par pilier (`matching_config`) :

```
S = 0{,}5\,T_{set} + 0{,}3\,JW + 0{,}2\,J_{sig} - P_{disc} - P_{comp}
```

- T_set : similarité par ensembles de mots (insensible à l'ordre : `TOXO(IgG et IgM)` contre `Sérologie toxoplasmose (IgG + IgM)`).
- JW : Jaro-Winkler sur la chaîne compacte, robuste aux fautes de frappe (`RAIDOGRAPHIE`, `DOPPPLER`, `OBSTRECTRICALE`).
- J_sig : Jaccard sur les mots significatifs.
- P_disc : 0,25 par mot discriminant présent d'un côté et absent ou différent de l'autre (`IgG` contre `IgM`, `face` contre `face et profil`, `recherche` contre `sérologie`).
- P_comp : 0,20 si l'un est un bilan et l'autre un acte unitaire.

La **marge** est l'écart entre le premier et le deuxième candidat. Une marge faible signale une ambiguïté, même avec un score élevé.

8.3 Classement en trois issues

Issue	Règle V1 (prudente)	Règle V2 (après calibration)	Ce que voit l'opérateur
Reconnu	Étapes 1 à 4 (identifiant, nom, alias)	V1 + « équivalence de forme » : S ⩾ 0,95, marge ⩾ 0,10, aucun mot discriminant en conflit	Rien à faire ; contrôle par échantillon

Issue	Règle V1 (prudente)	Règle V2 (après calibration)	Ce que voit l'opérateur
À confirmer	Meilleur S ⩾ 0,60	Idem	Le candidat 1 pré-sélectionné, les candidats 2 et 3 à côté
Inconnu	Meilleur S < 0,60	Idem	Les 3 meilleurs candidats quand même, une recherche libre, et « proposer un nouvel acte »

Même « inconnu » propose : c'est la réponse à l'exigence « proposer plutôt qu'échouer ». Les seuils 0,60 / 0,95 / 0,10 sont des valeurs de départ, à recaler sur les données (8.5).

8.4 Bilans et actes composés

- Un libellé composé (`NFS + FROTIS SANGUIN` , `TPTCK (TC-TS)`) est d'abord cherché tel quel parmi les bilans.
- Sinon il est découpé ; si chaque morceau est reconnu et que l'ensemble correspond aux composants d'un bilan existant, ce bilan est proposé.
- Si l'ensemble ne correspond à aucun bilan, on propose « bilan propre à la structure », composé des actes reconnus, avec son prix à lui. Il rejoint la file des propositions d'actes si plusieurs structures le vendent.
- Un bilan ne se substitue jamais à ses actes : « Bilan hépatique » ne crée pas de tarif pour « ASAT ».

8.5 Ce que montre le fichier Bionissa

Sur 199 libellés, le matcher restrictif donne 127 reconnus (64 %), 68 à confirmer (34 %) et 4 inconnus (2 %). Parmi les 68 à confirmer, 41 ont un score flou ⩾ 95 %, dont 39 à 100 %.

La plupart de ces 41 sont justes (`Ac anti HBs` → Anticorps anti-HBs). Mais plusieurs à 100 % sont faux ou discutables : `RECHERCHE CHLAMYDIA` → Sérologie Chlamydia (une recherche directe n'est pas une sérologie), `RECHERCHE MYCOPLASME` → Sérologie Mycoplasme, `METANEPHRINE` → Métanéphrines plasmatiques (urinaires ?). Un score élevé seul ne suffit donc pas : c'est pourquoi la règle V2 exige aussi l'absence de conflit sur les mots discriminants.

Avec la règle V2, l'automatique passerait d'environ 64 % à environ 80 % sur ce fichier, à vérifier ligne à ligne. Bionissa a servi à construire le référentiel : le vrai test est un deuxième laboratoire.

Calibration. Chaque décision humaine devient un exemple étiqueté. Les seuils sont recalés par pilier sur ce jeu : on retient le seuil automatique le plus bas qui donne **zéro erreur** sur l'historique, avec un minimum de 200 décisions par pilier avant d'activer la règle V2.

9. Écriture des alias et boucle d'apprentissage

Chaque confirmation ou correction crée un alias : c'est ce qui fait baisser le travail à chaque structure. Mais un alias global faux contaminerait tous les onboardings suivants, donc il passe par deux niveaux de confiance.

9.1 Règles d'écriture

- **Ce qu'on stocke** : `alias_norm` (forme normalisée, clé de recherche) et `alias_brut` (le texte d'origine, pour l'audit). Le libellé contextualisé est stocké quand c'est lui qui a été validé (`echographie abdominale` , pas `abdominale`).
- **Ce qu'on refuse** : un alias identique au nom de l'acte (inutile), de moins de 3 caractères, ou figurant dans la liste des termes trop génériques du pilier (`bilan` , `serologie` , `echographie` , `scanner` seuls).
- **Pas d'alias en double** : un même `alias_norm` ne pointe que vers un acte par pilier et par portée.

9.2 Deux niveaux de confiance

Niveau	Créé quand	Effet	Passage au niveau suivant
Alias de la structure (`scope = structure` , `actif`)	L'opérateur confirme ou corrige une ligne	Reconnu automatiquement pour cette structure dès sa prochaine mise à jour	—
Candidat global (`scope = global` , `candidat`)	En même temps que le précédent	Pour les autres structures : proposé en tête, mais toujours « à confirmer »	Validé par le référent médical, ou confirmé à l'identique par 2 structures différentes
Alias global (`scope = global` , `actif`)	Promotion du candidat	Reconnu automatiquement pour toutes les structures	—

9.3 Conflits

Si un opérateur rattache un `alias_norm` déjà actif à un **autre** acte, l'alias passe en `ambigu` : il ne déclenche plus jamais de reconnaissance automatique, et le conflit part dans la file du référent médical. Un alias peut être suspendu sans être supprimé ; l'historique de ses décisions reste consultable.

9.4 Amorçage

Au démarrage, le lexique est alimenté par :

- le référentiel biologie (415 actes, 19 types de service, lexique d'intention par acte), importé comme alias globaux `seed` ;
- le dictionnaire `MEDICAL_SYNONYMS` actuel, repris en alias `seed` après relecture ;
- l'export JSON des alias validés dans la réconciliation Bionissa (`alias_valides_bionissa.json`), importé en alias globaux actifs une fois les choix relus par le référent médical.

10. Validation humaine et publication

L'opérateur ne voit que ce qui demande un jugement, dans l'ordre où son temps rapporte le plus ; la publication est une étape séparée, contrôlée et annulable.

10.1 Écran de validation (back-office d'onboarding)

- **File triée** : inconnus, puis à confirmer par score croissant, puis un échantillon de 5 % des reconnus pour contrôle.
- **Par ligne** : libellé brut, section, libellé contextualisé, prix lu, candidat 1 pré-sélectionné, candidats 2 et 3, score et explication (« alias Bionissa », « flou 92 %, conflit IgG/IgM »), et l'aperçu de l'alias qui sera créé.
- **Actions** : valider, choisir un autre candidat, chercher dans le référentiel, marquer « hors référentiel » (crée une `ActeProposition`), ignorer (titre, commentaire, doublon), corriger le prix.
- **Actions groupées** : valider tous les candidats 1 d'une section au-dessus d'un score choisi, après affichage de la liste.
- **Clavier** : navigation et validation sans souris, pour tenir le rythme sur 200 lignes.
- **Doublons dans le fichier** : deux lignes vers le même acte sont signalées côte à côte ; l'opérateur choisit le prix retenu (pas de « dernier prix vu » silencieux comme aujourd'hui).

10.2 Conditions de publication

- La structure a un identifiant MedCare (statut au moins `pre_inscrite`).
- Chaque ligne a une `Decision`.
- Chaque ligne publiée a un prix `renseigne` ou `sur_devis` ; aucune anomalie de prix ouverte.
- Le référentiel utilisé est à jour (version synchronisée = version de production).

10.3 Publication

1. **Diff** contre l'offre existante de la structure : actes créés, prix modifiés, inchangés, et actes présents en production mais absents du fichier. L'opérateur valide ce diff.
2. **Écriture** en une transaction via l'API de publication : `PrestataireActe` créés ou mis à jour avec `origine`, `lot_publication_id`, `libelle_structure`, et `confirme_par_structure_le` vide.
3. **Jamais de suppression** : un acte absent du fichier est signalé, pas retiré.
4. **Annulation** : un lot peut être annulé ; on restaure l'état précédent des lignes qu'il a touchées (valeurs avant/après conservées dans le lot).
5. **Invitation** : si le compte n'est pas réclamé, envoi du lien d'activation (SMS / WhatsApp / e-mail).

10.4 Première connexion de la structure

La structure arrive sur un écran « Votre catalogue a été préparé par MedCare » : la liste de ses actes avec son libellé à elle et l'acte MedCare en regard, ses prix modifiables, et un bouton « Je confirme mes tarifs ». La confirmation rend le catalogue visible des patients. Une correction de la structure sur un rattachement remonte en décision à revoir côté MedCare (et donc en signal sur l'alias).

11. Scénarios d'onboarding

Quatre canaux alimentent le même moteur ; seule l'entrée change. Recommandation : **A pour le pilote des 50 structures, B en parallèle dès qu'il est prêt, C après calibration, D (chatbot) en V2.**

Scénario	Entrée	Qui fait quoi	Effort structure	Effort MedCare	Quand
A. Assisté (fichier libre)	Le fichier tel qu'il existe, envoyé par WhatsApp, e-mail ou déposé via le lien	MedCare pré-inscrit, importe, valide, publie ; la structure confirme ses tarifs	Envoyer un fichier, confirmer	Élevé au début, décroissant avec le lexique	V1, pilote
B. Gabarit MedCare	Un tableur généré par pilier : actes du référentiel avec leur ID, colonnes prix et délai à remplir, listes déroulantes	La structure coche et tarife ; l'ID rend le rapprochement exact	Remplir les prix	Quasi nul	V1, en parallèle
C. Self-service	Upload par la structure via son lien ou son compte	Même chaîne ; la structure voit les reconnus, MedCare tranche les doutes en arrière-plan	Faible	Faible, limité aux doutes	V2, après calibration

Le gabarit sert aussi aux mises à jour. Une fois la structure active, MedCare exporte son gabarit pré-rempli (ses actes, ses prix actuels) : elle corrige et renvoie, et le réimport est exact par ID. C'est le canal le moins coûteux à terme.

Petites structures (moins de 20 actes) : la saisie guidée dans le tableau de bord actuel reste possible, mais avec recherche dans le référentiel et autocomplétion par les alias, pour ne plus taper l'acte en entier.

Scénario D — Chatbot d'onboarding (V2). Le chatbot est une nouvelle entrée sur le même moteur, pas un moteur à part. Il présuppose que les scénarios A et B tournent et que l'API du service est stable.

- **Canal** : WhatsApp Business en priorité (le canal déjà utilisé par les secrétaires), widget web en second.
- **Collecte** : la structure envoie son fichier ou une photo de sa grille tarifaire ; le bot accuse réception, rattache l'envoi au bon dossier par le numéro de téléphone et le jeton d'onboarding.
- **Questions ciblées** : au lieu d'attendre l'opérateur, le bot pose à la structure les questions qu'elle seule peut trancher, en réponses rapides : prix manquant (`SCANNER CERVICO-DORSO-LOMBAIRE` : quel tarif ?), prix suspect (`TOGD` : 700 000 F ou 70 000 F ?), sens d'un libellé (`OBSTETRICALE DE CONTRÔLE` : échographie obstétricale de suivi ?).
- **Suivi** : le bot donne l'état du dossier (reçu, en validation, publié) et envoie le lien d'activation du compte.

- **Garde-fou** : un modèle de langage peut aider à lire une photo ou à reformuler une question, mais il ne décide jamais d'un rattachement. Les règles de la section 8 et la validation humaine restent seules juges.
- **Prérequis** : compte WhatsApp Business API, consentement CDP sur les échanges, journal des conversations rattaché au dossier.

12. Évolutions de l'application actuelle

L'application MedCare doit évoluer sur six points pour accueillir l'onboarding ; le plus structurant est d'avoir **un seul moteur de rapprochement**, utilisé par le service d'onboarding et par l'import du tableau de bord structure.

Zone	Évolution	Fichiers concernés
Moteur	Extraire normalisation + rapprochement dans un paquet Python partagé (`medcare_matching`), sans Django, testé seul. `catalog_excel.py` l'appelle au lieu de sa propre logique	`healthcare/catalog_excel.py`, `catalog_importer.py`
Import structure	Passe de « rejet » à « proposition » : les doutes créent un dossier en validation au lieu d'une erreur. Prix vide ≠ 0	`views_prestataire.py`, `actes_list.html`
Modèle	Migrations de la section 5 : `ActeAlias`, `ActeComposant`, `ActeProposition`, champs sur `ActeMedical`, `PrestataireActe`, `OrganismeDeSante`	`healthcare/models.py`
Comptes	Pré-inscription, jeton d'onboarding, activation de compte sur fiche existante	Auth, inscription structure
Tableau de bord structure	Écran « catalogue préparé » + confirmation des tarifs ; export du gabarit pré-rempli	Templates prestataire
Back-office admin	Gestion du référentiel : actes, bilans, alias (statuts, conflits), file des propositions d'actes	Admin MedCare

Les tests existants (`test_catalog_excel.py`, 15 scénarios) sont conservés et complétés par les cas de l'annexe. Le référentiel biologie (415 actes) est chargé par une migration de données à partir de son export JSON.

12.1 Pile technique (Python)

Le programme d'onboarding est écrit en Python, dans la continuité de la plateforme Django existante.

Couche	Choix	Pourquoi
Langage	Python 3.12	Même langage que la plateforme et que `catalog_importer.py`
Moteur de rapprochement	Paquet `medcare_matching` en Python pur, testé avec pytest	Utilisable par le service d'onboarding, par Django et par un script en ligne de commande
Lecture des fichiers	pandas + openpyxl (.xlsx), odfpy (.ods), LibreOffice headless (.xls), module csv	Couvre les formats V1 de la section 6
Score flou	rapidfuzz (`token_set_ratio` , Jaro-Winkler)	Rapide en C, licence MIT, remplace `difflib`
Normalisation	`unicodedata` + tables d'abréviations en base	Pas de règle métier en dur
Service d'onboarding	Django 5 + Django REST Framework, déploiement distinct	Réutilise modèles, authentification et admin ; une seule compétence dans l'équipe
Traitements longs	Celery + Redis	Lecture et rapprochement d'un gros fichier sans bloquer l'écran
Base	PostgreSQL, schéma `onboarding` séparé	Isolation des données sales, même moteur que la production
Stockage des fichiers	Stockage objet S3 compatible sur le cloud souverain	Fichiers originaux immuables, hors base
V2	pdfplumber (PDF), OCR, API WhatsApp Business (chatbot)	Scénarios C et D

13. Indicateurs et économie d'échelle

L'architecture est réussie si le temps opérateur par structure baisse à chaque onboarding, à qualité constante. Ces indicateurs sont calculés par dossier et par pilier depuis les tables `Decision` et `LotPublication` , sans instrumentation supplémentaire.

Indicateur	Calcul	Sens attendu
Taux de reconnaissance automatique	Lignes `reconnu` / lignes d'actes	Monte avec le lexique

Indicateur	Calcul	Sens attendu
Lignes à traiter pour 100	(à confirmer + inconnus) / lignes × 100	Baisse
Temps opérateur par dossier	Somme des durées entre première et dernière décision humaine	Baisse
Précision de l'automatique	Reconnus corrigés ensuite (contrôle, structure) / reconnus	Reste à 0 ; une hausse coupe la règle V2 du pilier
Réutilisation du lexique	Lignes reconnues grâce à un alias créé par une autre structure / reconnus	Monte : c'est l'effet d'échelle
Délai fichier → catalogue publié	`publie_le` – date du premier fichier	Baisse
Taux d'activation	Comptes réclamés / structures publiées, à 7 et 30 jours	Monte
Corrections après confirmation	Rattachements modifiés par la structure	Bas

Les cibles chiffrées (temps par dossier, taux automatique) sont à fixer après les trois premiers laboratoires hors Bionissa : ce sont eux qui donneront la vraie courbe.

14. Plan de livraison et décisions à arbitrer

La livraison se fait en cinq lots de deux semaines ; le pilote peut démarrer en scénario A dès la fin du lot 3. Chaque lot se termine par une démonstration sur un vrai fichier de structure.

14.1 Lots

1. **Lot 0 — Fondations.** Migrations du modèle (section 5), pré-inscription et statut d'onboarding, chargement du référentiel biologie et des alias d'amorçage, paquet `medcare_matching` extrait avec ses tests.
2. **Lot 1 — Ingestion.** Lecture de tous les formats V1, détection de schéma et de sections, écran de validation de la lecture, stockage brut et normalisé. Critère : le fichier imagerie de l'annexe est lu à 112 lignes, 5 sections, 0 plantage.
3. **Lot 2 — Rapprochement et validation.** Cascade, score, trois issues, écran de validation, création d'alias. Critère : Bionissa rejoué à l'identique (64 / 34 / 2) en règle V1.

4. **Lot 3 — Publication et activation.** Diff, API de publication, annulation de lot, lien d'onboarding, écran « catalogue préparé » côté structure. Critère : une structure pré-inscrite réclame son compte et trouve son catalogue.
5. **Lot 4 — Gabarit et calibration.** Génération du gabarit par pilier, réimport par ID, tableau de bord des indicateurs, calibration des seuils, référentiel imagerie.

14.2 Décisions à arbitrer

#	Décision	Options	Recommandation	Qui
D1	Compte d'une structure pré-inscrite	`user` nullable / `User` inactif créé d'office	`User` inactif : moins de cas particuliers dans le code existant	Rassoul
D2	Forme de l'environnement séparé	Service distinct + schéma dédié / app Django dans le monolithe	Service distinct, même cloud, une seule API d'écriture	Rassoul
D3	Largeur de l'automatique au pilote	V1 (exact seulement) / V2 dès le départ	V1, puis V2 par pilier après 200 décisions	Rassoul + Abdoul
D4	Qui promeut un alias en global	Référent médical seul / référent ou 2 structures concordantes	Référent ou 2 structures	Abdoul
D5	Visibilité patient après publication	Immédiate / après confirmation des tarifs par la structure	Après confirmation	Abdoul
D6	Bilans propres à une structure	Refusés / acceptés comme bilans locaux	Acceptés comme bilans locaux	Abdoul
D7	Référentiel imagerie	À construire avant le premier centre d'imagerie / au fil des fichiers	À construire d'abord, sur le modèle du référentiel biologie	Abdoul

Point ouvert. Le prototype actuel (162.19.67.106:8085) est à revoir avec le développeur en s'appuyant sur ce manuel : ce qui est réutilisable (lecture de fichier, écran) et ce qui doit être repris (à vérifier en priorité : zone de staging, traitement des lignes non trouvées, dépendance au compte connecté).

Annexe — Cas de test : fichier imagerie *ACTES ET TARIFICATIONS*

Ce fichier réel (.ods, 1 feuille, 112 lignes, 5 sections : Échographies, Scanner, IRM, Examens spéciaux, Radiographies) concentre presque toutes les difficultés d'un fichier de structure. L'outil actuel le rejette en entier : plantage sur le format .ods, puis « En-têtes non reconnus » une fois converti en .xlsx. Il devient le test de non-régression du lot 1.

Ligne	Contenu brut	Difficulté	Comportement attendu
1	`ECHOGRAPHIES` … `PRIX`	Pas de colonne « Acte », en-tête répété par section	Titre de section ; colonne 1 = libellé, colonne 8 = prix par profil
3	`ABDOMINALE` — `20000 F`	Libellé incomplet sans la section	Contextualisé en `echographie abdominale` → reconnu
6	`OBSTETRICALE DE CONTRÔLE` — `15000 F`	Variante d'un acte (contrôle)	À confirmer vers Échographie obstétricale, ou proposition d'acte
22	`ECHOGRAPHIE DOPPPLER RENAL`	Faute de frappe	Flou (Jaro-Winkler) → à confirmer
23	`ECHOGRAPHIE DOPPLER OBSTRECTRICALE`	Faute de frappe	Flou → à confirmer
36	`SCANNER DU` | `MASSIF FACIAL`	Libellé sur deux colonnes	Recollé en `scanner du massif facial`
42	`SCANNER CERVICO-DORSO-LOMBAIRE` — vide	Prix manquant	Statut `manquant`, bloque la publication de la ligne, pas 0 FCFA
63	`IRM DES GENOUX` — `300000 F`	Bilatéral, à côté de `IRM GENOU`	Mot discriminant pluriel / bilatéral : jamais fusionné avec IRM genou
79	`TOGD` — `700000 F`	Sigle + prix aberrant	Rapprochement par sigle ; anomalie de prix signalée
90	`RAIDOGRAPHIE DU THORAX FACE & PROFIL`	Faute + discriminant	À confirmer, distinct de `RADIOGRAPHIE DU THORAX DE FACE`
100	`RADIOGEPHIE DU POIGNET`	Faute de frappe	Flou → à confirmer

Ligne	Contenu brut	Difficulté	Comportement attendu
110	`RADIOGRAPHIE DU BASSIN DE FACE ET PROFIL`	Discriminant face / profil	Distinct de `… DE FACE` (ligne 109)

Numéros de ligne tels qu'affichés dans le tableur. Le référentiel imagerie de l'outil actuel ne compte qu'une vingtaine d'actes : la plupart de ces lignes seraient « inconnues » aujourd'hui, ce qui confirme la décision D7.